

저가형 자이로 센서의 드리프트 감소 방안에 대한 고찰

Some Observations on Drift-Reduction Methods for Low-cost Gyro Sensors

남동균¹ · 박주영¹ · 박현우² · 김도윤²

Dongkyun Nam, Jooyoung Park, Hyunwoo Park, and Do-Yoon Kim

¹고려대학교 제어계측공학과

E-mail: {skadas, parkj}@korea.ac.kr

²위드로봇

E-mail: {irmusy, getcome}@gmail.com

요 약

자이로 드리프트(gyro drift)는 진행방향각도(yaw)를 추정하는 과정에 오차(error)를 증가시켜 자이로 센서를 활용하는 각종 시스템의 성능을 떨어뜨리는 주요 원인이 되고 있다. 본 논문은 폐루프 제어 시스템(closed-loop control system)을 이용하여 저가형 자이로 센서의 드리프트(drift)를 감소시키는 HDR 알고리즘에 강화학습의 일종인 CARLA 기법을 적용하여 적절한 파라미터를 찾아내는 방안에 대한 가능성을 고찰한다. 그리고 실험 장치를 구성하여 성능평가를 실시하고 실험 결과를 기반으로 드리프트(drift)가 감소한 효과를 확인한다.

키워드 : gyro, drift reduction, HDR, CARLA

1. 서 론

자이로(gyro) 센서는 회전율(rate-of-turn) ω 정보를 출력한다. 이러한 출력 정보를 수치적으로 적분하면 각도 정보를 얻을 수 있고 본 논문에서 관심을 두고 있는 진행방향각도(yaw)를 계산할 수 있다. 하지만 저가형 자이로 센서의 드리프트(drift)는 진행방향각도(yaw)를 추정하는 과정에 오차(error)를 증가시켜 자이로 센서를 활용하는 각종 시스템의 성능을 떨어뜨리는 주요 원인이 되고 있다. 이러한 드리프트(drift)를 최소화하기 위해 최근에 자이로 센서 정보만으로 폐루프 제어 시스템(closed-loop control system)을 이용하여 드리프트(drift)를 감소시키는 HDR 알고리즘이 소개된 바 있다[1].

[2][3]에서 소개된 CARLA(continuous action reinforcement learning automata)기법은 가우시안 분포 함수(gaussian distribution function)를 통해 적절한 액션의 선택 확률을 높여가는 전략을 사용하는 강화학습 기법의 일종이다.

본 논문에서는 자이로 센서 정보를 사용하여 드리프트(drift)를 감소시키는 HDR 알고리즘을 CARLA 기법으로 학습시키는 방향으로 개선하는 방안에 대한 가능성에 대하여 고찰한다. 그리고 실험 장치를 구성한 후 자이로 센서 데이터를 얻어 성능 평가를 실시하고 실험 결과를 기반으로 드리프트(drift) 감소 효과를 확인한다.

2. HDR 알고리즘을 이용한 자이로 드리프트 감소

정확한 진행방향각도(yaw)를 계산하기 위해 사용된 폐루프 제어 시스템(closed-loop control system)은 자이로 센서 정보만 이용하여 실시간으로 드리프트(drift)를 추정하고 제거하게 된다[1]. 여기서 중요한 역할을 하는 I -제어기(I -controller)는 다음과 같이 계산한다.

$$I_i = I_{i-1} - \text{SIGN}(\omega_{i-1})i_e \quad (1)$$

I 값은 고정된 증가값(fixed increment) i_e 만큼 적분되면서 결정되는데 자이로 센서의 회전 방향에 따라 그 부호가 결정된다. 즉, $\text{SIGN}(\omega_{i-1})$ 는 센서 출력값이 양수면 1, 0이면 0, 음수면 -1을 반환(return)한다. I -제어기(I -controller)는 드리프트(drift)의 변화를 추적하게 되고 식 (2)와 같이 드리프트(drift) ϵ_d 를 제거하여 보상된 회전율(rate-of-turn)을 구할 수 있다.

$$\omega_i = \omega_{true} + \epsilon_d + I_i \quad (2)$$

하지만 현실적인 상황에서의 흔들림(swaying), 약회전(curving), 강회전(turning)을 고려하기 위해 저대역 통과 필터(low-pass filter), 회전 스위치(turn switch), 반복 감쇠기(repetition attenuator)를 추가하여 현실적 조건을 감안한 알고리즘을 구성해야 한다[1].

첫 번째로 저대역 통과 필터(low-pass filter)를 식 (3)과 같이 수행하여 센서 출력에서 노이즈(noise)를 제거한다.

$$\omega'_i = \frac{\omega'_{raw,i}T_i + \tau\omega'_{i-1}}{T_i + \tau} \quad (3)$$

여기서 T_i 는 샘플링 시간(sampling time), ω' 는 필터

감사의 글 : 본 연구는 2010년 u-Transportation 기반기술 개발, 과제번호: 06-교통핵심-A01-01에 의해 수행되었습니다, 연구비 지원에 감사드립니다.

링된 값, τ 는 필터 시간 상수(filter time constant)이다.

두 번째로 자이로 센서값의 $|\omega|$ 가 임계값(threshold)을 초과하면 식 (4)의 회전 스위치(turn switch) W_i 가 동작하게 되고 식 (1)의 i_c 값이 0이 되어 I -제어기(I -controller)가 일정하게 유지된다.

$$W_i = \begin{cases} 0 & \text{for } \omega_{i-1} < \Theta_w \\ 1 & \text{for } \omega_{i-1} \geq \Theta_w \end{cases} \quad (4)$$

여기서 W_i 는 회전 스위치(turn switch), Θ_w 는 회전 임계값(turn threshold)를 나타낸다.

세 번째로 반복 감쇠기(repetition attenuator) R_i 는 약 회전(curving)과 드리프트(drift)사이를 구분하는데 필요하게 된다. 우선 반복 카운터(repetition counter) r 을 정의한다. 즉, 자이로 센서의 같은 부호가 유지하게 되면 식 (5)와 같이 r 값은 1씩 증가하게 된다.

$$r_i = \begin{cases} r_{i-1} + 1 & \text{for } \text{SIGN}(\omega_{i-1}) = \text{SIGN}(\omega_{i-2}) \\ 1 & \text{for } \text{SIGN}(\omega_{i-1}) \neq \text{SIGN}(\omega_{i-2}) \end{cases} \quad (5)$$

그리고 나서 식 (6)에 따라 r 값이 증가하면 반복 감쇠기(repetition attenuator) R_i 는 지수 함수적으로 감소하게 된다.

$$R_i = \frac{1 + c_1}{1 + c_1 r_i^{c_2}} \quad (6)$$

여기서 c_1 은 감쇠기 상수(attenuator constant), c_2 는 감쇠기 거듭제곱(attenuator power)을 나타낸다.

세 가지 사항을 포함한 알고리즘에서의 I -제어기(I -controller)는 식 (7)과 같이 계산할 수 있다.

$$I_i = I_{i-1} - \text{SIGN}(\omega_{i-1}) W_i R_i i_c \quad (7)$$

마지막으로 노이즈(noise)제거를 위해 사용한 저대역 통과 필터(low-pass filter)로 인해 시간 지연(time lag)이 발생하게 된다. 하지만 필터를 반전시킨 식 (8)을 이용하면 시간 지연(time lag)문제를 해결할 수 있고 그림 2와 같이 최종적인 자이로 드리프트 감소 알고리즘을 구성할 수 있다[1].

$$\omega_{d,i} = \omega_i + \frac{\tau}{T_i} (\omega_i - \omega_{i-1}) \quad (8)$$

그림 2의 드리프트 감소 알고리즘이 최고의 성능을 발휘하기 위해서는 식 (1), (3), (4), (6)에서 최적의 파라미터 i_c , τ , Θ_w , c_1 , c_2 를 찾아야 한다. 이러한 파라미터는 일반적으로 여러 차례의 실험을 통해 경험적으로 선택된다. 본 논문에서는 이상에서 설명된 그림 2의 경험적 드리프트 감소 알고리즘 HDR(heuristic drift reduction)에 강화학습의 일종인 CARLA 기법을 활용하는 방안에 대해 고찰한다.

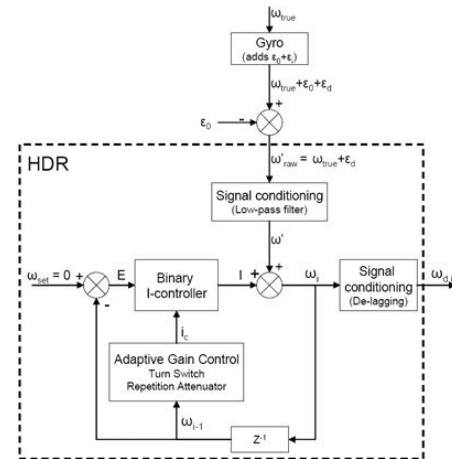


그림 2. 경험적 드리프트 감소 알고리즘 구성도[1]

Fig 2. Block diagram of the HDR algorithm[1]

3. 연속적 액션 강화학습 오토마타(CARLA)

참고 문헌 [2],[3] 등에서 소개된 CARLA(continuous action reinforcement learning automata)는 이산 학습 오토마타(discrete learning automata)로부터 발전한 학습 방법론이다. 확률적인 학습 오토마타(stochastic learning automata)는 유한한 크기의 이산 액션 집합 $\{x_1, x_2, \dots, x_r\} \in X$ 으로부터 임의의 액션들이 상호간에 별다른 결합 없이 선택되는 강화학습 방법의 일종이다. CARLA에서는 이산형 액션 공간을 연속형으로 대체함으로써 연속적인 액션을 선택할 수 있는데 알고리즘을 적용하는 환경도 연속적이라고 가정하므로 비슷한 액션의 선택은 비슷한 결과를 초래한다. 이 때 적절한 액션은 가우시안 분포함수(gaussian distribution function)를 통해 그 선택 확률을 높여 간다. 다시 말해 학습이 진행될수록 좋은 액션은 가우시안 분포함수(gaussian distribution function)를 따라 확률 밀도(probability density)를 증가시키는 전략을 사용하는 것이다.

이러한 CARLA기법은 그림 3과 같이 요약될 수 있다 [2].




그림 3. 연속적 액션 강화학습 오토마타[2]

Fig 3. Continuous action reinforcement learning automata[2]

하나의 학습 오토마타(learning automata)는 비교적 간단한 유닛이지만 그림 4와 같이 다중 액션으로 구성되면 복잡한 시스템에도 적용할 수 있다[2]. 시스템과 연결된 다수의 오토마타의 상호 결합을 사용할 수 있음은 다양한 종류의 제어 문제 및 복잡한 구조의 파라미터를 탐색하는 문제 등에 대한 적용가능성으로 이어질 수 있다.




그림 4. 상호 연결된 오토마타[2]
Fig 4. Interconnected automata[2]

4. CARLA와 HDR의 결합을 이용한 자이로 드리프트 감소

HDR 알고리즘에서 사용된 파라미터들은 일반적으로 여러 차례의 실험으로부터 경험적으로 결정된다[1]. 그리고, 퍼지 학습이론을 이용하여 i_c 값을 결정하는 방법도 제안된 바 있다[4].

본 논문에서는 CARLA 기법을 활용하여 HDR의 파라미터를 체계적으로 결정하는 방안을 고려한다. 학습과정에서는, 10개의 데이터 세트(data set)를 학습 데이터(training data)로 사용하였고($N=10$) 성능지수(performance index)인 비용 함수(cost function) PI는 식 (9)와 같이 정의하였다.

$$PI = \frac{1}{N} \sum_{i=1}^N \left(\frac{1}{n} \sum_{j=1}^n (\psi_{d,j} - \psi_{encoder,j})^2 \right) \quad (9)$$

위의 식의 PI는 알고리즘으로부터 보상된 자이로 센서 값을 수치적 적분하여 얻은 각도 ψ_d 와 엔코더(encoder) 각도 $\psi_{encoder}$ 사이의 평균 제곱 오차(mean square error)를 각 학습 데이터마다 구한 후 평균한 값으로 결정한다. 반복(iteration)이 진행될수록 PI 값은 감소하게 되고 학습 진행 여부를 확인할 수 있는 평가 지수(performance index)의 역할을 적절하게 수행할 수 있다.

CARLA 기법으로 학습 데이터(training data)에 대한 성능지수를 최적화하는 HDR의 파라미터를 결정한 후, 학습 데이터에 포함되어 있지 않은 평가 데이터(test data)를 대상으로 하여 성능확인 작업을 수행하였다.

5. 실험 및 결과

5.1 실험 장치

본 논문에서는, 그림 5와 같이 회전하는 원판위에 저가형 자이로 센서를 설치하는 방법으로 실험장치를 구성하여 필요한 데이터를 얻은 후 학습 및 평가과정을 수행하였다.




그림 5. 데이터 획득을 위한 하드웨어
Fig 5. Hardware for data acquisition

아울러, 원판 아래에는 엔코더(encoder)를 설치하여 정확한 회전 각도를 구한 후 PI 값을 구하기 위한 기준값(reference)으로 사용하였다.

5.2 학습 결과

실험 장치로부터 10개의 데이터 세트(data set)을 얻은 후 학습 데이터(training data)로 사용했을 때 그림 6과 같이 반복(iteration)이 진행될수록 비용(cost) 값 PI가 감소하는 경향을 관찰할 수 있다. 즉, 학습이 효과적으로 진행되었음을 확인할 수 있다.




그림 6. 반복이 진행됨에 따른 비용감소
Fig 6. Reduction in cost per iteration

그리고 본 논문에서 제안한 CARLA 기법으로 추정한 파라미터의 확률 분포 변화는 그림 7과 같고 확률 밀도(probability density)가 증가하면서 얻은 최적의 파라미터 값은 표 1에 정리되었다.




그림 7. 각 파라미터의 확률 분포 변화
Fig 7. The variation in probability density for each parameter

표 1. 학습 결과

Table 1. The learning results

Nominal increment	i_c	0.0006
Low-pass filter time constant	τ	0.9447
Turn threshold	Θ_w	0.5608
Repetition attenuator constant	c_1	0.7839
Repetition attenuator power	c_2	1.2161

파라미터를 결정한 후 학습 여부를 실질적으로 확인해 보기 위해 10개의 학습 데이터 중 하나를 대상으로 학습 여부를 확인해 본다. 그림 8과 9는 자이로 드리프트 감소 알고리즘 적용 전 후의 진행방향각도(yaw)와 엔코더(encoder)와의 오차를 보여준다.

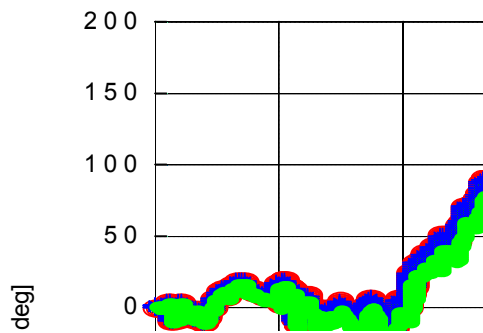


그림 8. 진행방향각도 비교 (30분 데이터)
Fig 8. Comparison of yaw angles (30minutes data)




그림 9. 진행방향각도 오차 비교
Fig 9. Comparison of errors in yaw angle

10개의 학습 데이터(training data)에 대한 오차를 수치적으로 표현하기 위해 식 (10)과 (11)을 이용하여 오차를 평균화(average errors)하고 회전 시간(T_d : 분 단위)으로 정규화시켜(normalized average errors) 표 2에 정리하였다. 도표의 내용에서 볼 수 있듯이 본 논문에서 시도한 CARLA와 HDR의 접목은 주어진 학습 데이터에 대해 비용함수를 줄여주는 효과적인 학습을 수행함을 알 수 있다.

$$E_{\psi} = \frac{1}{n} \sum_{i=1}^n |\psi_{gyro,i} - \psi_{encoder,i}| \quad (10)$$

$$NE_{\psi} = \frac{E_{\psi}}{T_d} \quad (11)$$

표 2. 오차 평균과 정규 오차 평균의 비교(학습 데이터)
Table 2. Comparison of average errors and normalized average errors(training data)

학습 데이터	오일러 적분		본 논문의 방법론	
	E_{ψ}	NE_{ψ}	E_{ψ}	NE_{ψ}
20100707 1시간(정지)	137.0291	2.3963	0.5072	0.0089
20100712 15분	29.6048	1.9282	0.5960	0.0388
20100726 30분	46.6630	1.4905	1.3441	0.0429
20100817 20분	8.6261	0.4645	1.8508	0.0997
20100817 40분	29.4852	0.7140	2.4821	0.0601
20100823 15분	2.0780	0.1331	0.6770	0.0434
20100823 20분	10.5761	0.5300	0.5163	0.0259
20100823 30분	16.2207	0.5243	1.2990	0.0420
20100823 40분	55.8339	1.3302	1.7499	0.0417
20100823 60분	159.1022	2.5959	1.9126	0.0312

5.3 성능 평가

CARLA 기법으로 추정된 파라미터를 적용한 자이로 드리프트 감소 알고리즘의 일반화 능력(generalization capability)을 확인하기 위하여, 파라미터 추정에 사용된 학습 데이터(training data) 외에 추가적인 데이터에 대한 성능을 확인해 볼 필요가 있다. 따라서 학습에 사용하지 않은 평가 데이터(test data)를 대상으로 성능 평가(performance evaluation)를 수행하였고 그 결과는 표 3과 같았다. 도표의 내용은 학습 결과 얻어진 파라미터 집합이, 일반적인 평가 데이터에 대해 좋은 성능을 제공하는 일반화 능력이 있음을 보여준다.

표 3. 오차 평균과 정규 오차 평균 비교(평가 데이터)
Table 3. Comparison of average errors and normalized average errors(test data)

평가 데이터	오일러 적분		본 논문의 방법론	
	E_{ψ}	NE_{ψ}	E_{ψ}	NE_{ψ}
20100827 35분	28.8227	0.8516	0.4164	0.0123
20100827 40분 1	71.5761	1.7752	1.7617	0.0437
20100827 40분 2	6.1498	0.1440	1.5123	0.0354
20100829 20분	10.7118	0.4957	1.1206	0.0519
20100829 40분	22.7681	0.5596	2.5046	0.0616
20100829 60분	51.6793	0.8810	2.1200	0.0361

6. 결 론

본 논문에서는 자이로 드리프트(gyro drift)를 감소시키기 위한 HDR 알고리즘[1]을 소개한 후, 경험적으로 추정했던 알고리즘의 파라미터를 CARLA(continuous action reinforcement learning automata) 기법으로 추정하는 방안을 고려하였다. 그리고 실험 장치를 구성하여 학습 데이터(training data)와 평가 데이터(test data)를 얻어 학습(learning)과 성능 평가(performance evaluation)를 수행하여 CARLA 학습 이론을 적용한 자이로 드리프트 감소 알고리즘의 성능을 실험적으로 확인하였다. 향후 과제로는, 본 논문에서 고려한 알고리즘을 이동로봇 또는 차량에 적용시키는 방향으로의 개선 등을 들 수 있다.

참 고 문 헌

- [1] J. Borenstein and L. Ojeda, "Heuristic reduction of gyro drift in vehicle tracking applications," Vehicle Autonomous Systems, Vol. 2, No. 1/2, pp. 78-98, 2009.
- [2] M. N. Howell, G. P. Frost, T. J. Gordon and Q. H. Wu, "Continuous action reinforcement learning applied to vehicle suspension," Mechatronics, Vol. 3, No. 3, pp. 263-276, 1997.
- [3] M. N. Howell and M. C. Best, "On-line PID tuning for engine idle-speed control using continuous action reinforcement automata," Control Engineering Practice, Vol. 8, No. 2, pp. 147-154, 2000.
- [4] H. Qian, Q. Xia, B. Liu, D. An and X. Peng, "Fuzzy heuristic reduction of gyro drift in gyro-based mobile robot tracking," Proceedings of the Information Engineering and Computer Science, 2009.